




IPU AI 방화벽: 시스템 아키텍처 및 기술 명세

기업용 생성형 AI 도입을 위한 문맥 유지형 보안 게이트웨이


대상 독자: 시스템 아키텍트, 보안 엔지니어 및 IT 인프라 담당자

엔터프라이즈 AI 아키텍처 비교 매트릭스

	외부 AI 차단	로컬 LLM 구축	단순 마스킹	IPU AI 방화벽
보안성	최상	상	중	상 (데이터 내부 통제)
인프라 비용	무료	최상 (GPU 종속)	저	저 (경량 미들웨어)
AI 추론 성능	불가	중 (SOTA 대비 열세)	하 (문맥 훼손)	최상 (외부 SOTA 활용)
문맥 유지율	N/A	상	최하	상 (동적 치환)


IPU는 보안(내부)과 지능(외부 SOTA AI)을 분리하여 막대한 GPU 투자 없이 고성능 AI를 안전하게 도입하는 인프라 전략입니다.

핵심 패러다임: 내부 보호와 외부 추론의 분리



IPU는 LLM 대체재가 아닙니다. 외부 최고 성능의 모델을 조직의 통제 하에 두는 정책 기반 요청/응답 게이트웨이입니다.

시스템 아키텍처 레이어



핵심 엔진 메커니즘: 문맥 유지형 치환

단순 마스킹 - 기존 방식

계약금 [MASK]원을 [MASK]에게 송금.

 AI 논리적 문맥 단절: 송금의 주체와 객체, 규모의 관계성을 상실하여 정확한 분석 및 요약 실패.

IPU 문맥 유지형 치환 - 제안 방식

계약금 [AMOUNT_ALIAS_01]원을
[PERSON_ALIAS_01]에게 송금.

 LLM 문맥 유지: 엔티티 간의 관계와 속성을 이해한 상태로 고도의 추론 수행.
세션 바인딩을 통해 유추 공격 방어.

데이터의 형태를 보존하는 동적 Alias 토큰을 통해, 보안 규칙을 준수하면서도 SOTA 모델의 인지 능력을 100% 활용합니다.

보안 정책 프리셋 (Security Policy Presets)

Policy: default

동작 방식: Alias 기반 문맥 유지형 치환

출력 예시: [EMAIL_ALIAS_01], [PERSON_ALIAS_01]

목적: 인간 검토자와 외부 AI가 문맥을 쉽게 파악하도록 가독성 극대화

적용 씬: 빠른 초안 검토, 일반 업무 지원, 컨텍스트 중심 분석

Policy: strict_token

동작 방식: 비가역적 형식의 엄격한 해시/난수형 토큰화

출력 예시: 8F92A-X91, 3B11C-Z00

목적: 가장 강력한 규제 환경을 위한 데이터 난독화 보장

적용 씬: 높은 컴플라이언스가 요구되는
금융/공공 핵심 데이터 처리

API Constraint Note: Backend API Schema는 default와 strict_token 두 가지만 허용하며, 미지원 Policy 요청 시 즉시 Reject 처리하여 시스템 안정성을 보장합니다.

세션 및 메모리 관리 명세

휘발성 매핑 아키텍처

매핑 데이터는 오직 내부 세션(session_id)에만 바인딩됨.

원본 데이터는 어떠한 경우에도 외부 LLM API로 전송되지 않습니다.

TTL (Time-To-Live) 설정

IPU_SESSION_TTL_SECONDS: 기본값 900초 (15분)
TTL 만료 시 원본 매핑 테이블은 자동 파기되어 영구적인 데이터 유출 경로를 원천 차단합니다.

스토리지 모드 스펙

SQLite Mode: 감사 및 히스토리 조회를 위한 로컬 지속성 보장



Memory Mode: 완전 휘발성 처리. 프로세스 종료 시 소멸 및
조회 시 503 Error 반환으로 극강의 보안 보장

Alias	Raw Data
[AMOUNT_ALIAS_01]	10,000,000원
[PERSON_ALIAS_01]	김철수
[EMAIL_ALIAS_01]	kimcs@example.com
...	...




TTL 만료 시 자동 파기
(Automatic Destruction)

데이터 플로우 스웸레인 (수동 모드 vs 자동 모드)



멀티모달 파이프라인 통합 아키텍처



`IPU_WHISPER_MODEL_NAME=small`

민감한 음성이 네트워크 외부로 나가기 전,
내부 폐쇄망에서 텍스트로 안전하게 전사 완료

로깅 및 감사(Audit) 전략


운영 메타데이터는 기록하되, 원문 및 매핑된 민감정보는 절대 로그로 남기지 않는다.

✓ 허용된 감사 메타데이터 (Allowed Audit Log)

```
{
  "session_id": "req-98x2-abc",
  "policy": "default",
  "detection_count": 14,
  "replacement_count": 14,
  "processing_ms": 104,
  "error_type": null
}
```


차단된 로깅 데이터 (Blocked Raw Data Log)

```
{
  "raw_input_text": "계약금 만원을...",
  "mapping_values": {
    "mapping_values": {
      "PERSON_NAME_1": "홍길동"
    }
  }
}
```



2차 데이터 유출(Secondary Data Leak) 취약점 없이 보안 부서에 완벽한 감사 통제력을 제공합니다.

배포 환경 티어 (Deployment Environments)



ops-target (엔터프라이즈 운영 환경)

- 온프레미스(On-Premise) 완벽 지원
- 엄격한 세션 정책 강제 및 영구 감사 로그 연동
- 엔터프라이즈급 트래픽 처리를 위한 아키텍처 격리


demo-stack (PoC 및 시연 환경)

- 정적 호스팅 Frontend + 단일 웹 Backend
- 실제 Whisper STT 라이브 통합
- **PDF / OCR Fallback** 파이프라인 포함

dev-local (빠른 구현 및 검증)

- 👤 단일 사용자 중심의 로컬 환경
- 💻 임시 가상환경(**fast venv**) 및 로컬 **SQLite** 허용
- 🦋 **Mock STT** 파이프라인으로 빠른 이터레이션

로드맵: MVP에서 엔터프라이즈 플랫폼으로



요약: 기술적 의사결정자를 위한 3가지 핵심



1. No GPU Heavy-Lifting (인프라 경량화)

수백만 원의 비용과 성능 한계를 가진 로컬 LLM 클러스터를 대체하는 가볍고 빠른 Python/React 기반 미들웨어 아키텍처.



2. Provable Security (입증 가능한 보안 설계)

원문 데이터 외부 전송 Zero. 휘발성 메모리 관리와 철저한 로그 격리로 기술적으로 보장되는 민감정보 통제력.



3. Seamless Integration (유연한 확장성)

내부 시스템과 최신 SOTA API 사이에 투명하게 배치되어 기존 업무 흐름의 훼손 없이 즉각적인 보안 계층 제공.

제한된 범위(특정 부서/문서)에서의 2~4주 PoC를 통해
실제 업무 흐름에서의 완벽한 동작을 직접 검증하십시오.